

Statistical Analysis with R in Saratoga Dataset

Εισαγωγή

Σκοπός της παρούσας μελέτης είναι εξαγωγή συμπερασμάτων για τα δεδομένα των σπιτιών της Saratoga. Το dataset που θα επεξεργαστούμε έχει τις ακόλουθες μεταβλητές: Price: η τιμή (σε 1000s \$) (εξαρτημένη μεταβλητή) lotSize: μέγεθος οικοπέδου (square feet) age: παλαιότητα του σπιτιού (years) landValue: αξία οικοπέδου (1000s of US dollars) livingArea: εμβαδό σπιτιού (square feet) pctCollege: ποσοστό γειτόνων που είναι απόφοιτη κολεγίου bedrooms: αριθμός υπνοδωματίων fireplaces: αριθμός τζακιών bathrooms: αριθμός μπάνιων rooms: αριθμός δωματίων heating type: τύπος θέρμανσης fuel: καύσιμο θέρμανσης sewer type: τύπος υπονόμου waterfront: ύπαρξη προκυμαίας newConstruction: αν είναι νεόδμητο centralAir: αν έχει κεντρικό αερισμό

Ερυνητικά ερωτήματα

Παρακάτω θα μελετήσουμε τη σχέση όλων των μεταβλητών με την τιμή του σπιτιού και θα προσπαθήσουμε να διερευνήσουμε το βαθμό της συσχέτισης τους με αυτήν κατασκευάζοντας κατάλληλα μοντέλα πρόβλεψης. Ακολούθως θα διερευνήσουμε κατά πόσο η διαισθητικά εύλογη συσχετίση του αν είναι νεόδμητο το σπίτι με το ποσοστό αποφοίτων κολεγίου της γειτονιάς, τον αριθμό δωματίων, την τιμή και (την εξ ορισμού) ηλικία της κατασκευής, επιβεβαιώνονται από τα δεδομένα μας:

```
system("defaults write org.R-project.R force.LANG el_GR.UTF-8")
```

```
## Warning in system("defaults write org.R-project.R force.LANG el_GR.UTF-8"):
## 'defaults' not found

## [1] 127
```

```
SH<-read.csv("D:/Desktop/SaratogaHouses.csv", header=T)
SH<-subset(SH, select=-c(X))
```

Η παρακάτω εντολή σημαίνει ότι η βάση δεδομένων αναζητείται από την R κατά την αξιολόγηση μιας μεταβλητής, έτσι ώστε τα αντικείμενα στη βάση δεδομένων να είναι προσβάσιμα προς ανάλυση δίνοντας απλώς τα ονόματά τους.

```
attach(SH)
```

Με την εντολή names() πραγματοποιείται εκτύπωση όλων των μεταβλητών στο πλαίσιο δεδομένων.

```
names(SH)
```

```

## [1] "price"          "lotSize"         "age"            "landValue"
## [5] "livingArea"     "pctCollege"      "bedrooms"       "fireplaces"
## [9] "bathrooms"      "rooms"          "heating"        "fuel"
## [13] "sewer"          "waterfront"     "newConstruction" "centralAir"

```

Πραγματοποιείται εκτύπωση των πρώτων 6 εγγραφών για κάθε στήλη του dataframe

```
head(SH)
```

```

##   price lotSize age landValue livingArea pctCollege bedrooms fireplaces
## 1 132500    0.09  42    50000      906       35       2        1
## 2 181115    0.92   0    22300     1953       51       3        0
## 3 109000    0.19 133     7300     1944       51       4        1
## 4 155000    0.41  13    18700     1944       51       3        1
## 5  86060    0.11   0    15000      840       51       2        0
## 6 120000    0.68  31    14000     1152       22       4        1
##   bathrooms rooms heating fuel           sewer waterfront
## 1        1.0    5 electric electric      septic      No
## 2        2.5    6 hot water/steam      gas      septic      No
## 3        1.0    8 hot water/steam      gas public/commercial      No
## 4        1.5    5 hot air      gas      septic      No
## 5        1.0    3 hot air      gas public/commercial      No
## 6        1.0    8 hot air      gas      septic      No
##   newConstruction centralAir
## 1             No        No
## 2             No        No
## 3             No        No
## 4             No        No
## 5            Yes       Yes
## 6             No        No

```

Με την εντολή summary() βρίσκονται όλα τα σημαντικά στατιστικά στοιχεία της εξαρτημένης και των ανεξάρτητων μεταβλητών(Διάμεσος , μέση τιμή, 1ο & 3ο τεταρτημόριο)

```
summary(SH)
```

```

##   price          lotSize          age          landValue
## Min. : 5000  Min. : 0.0000  Min. : 0.00  Min. : 200
## 1st Qu.:145000 1st Qu.: 0.1700  1st Qu.: 13.00  1st Qu.: 15100
## Median :189900 Median : 0.3700  Median : 19.00  Median : 25000
## Mean   :211967  Mean   : 0.5002  Mean   : 27.92  Mean   : 34557
## 3rd Qu.:259000 3rd Qu.: 0.5400  3rd Qu.: 34.00  3rd Qu.: 40200
## Max.   :775000  Max.   :12.2000  Max.   :225.00  Max.   :412600
##   livingArea      pctCollege      bedrooms      fireplaces      bathrooms
## Min. : 616  Min. :20.00  Min. :1.000  Min. :0.0000  Min. : 0.0
## 1st Qu.:1300 1st Qu.:52.00  1st Qu.:3.000  1st Qu.:0.0000  1st Qu.:1.5
## Median :1634  Median :57.00  Median :3.000  Median :1.0000  Median :2.0
## Mean   :1755  Mean   :55.57  Mean   :3.155  Mean   :0.6019  Mean   :1.9
## 3rd Qu.:2138 3rd Qu.:64.00  3rd Qu.:4.000  3rd Qu.:1.0000  3rd Qu.:2.5
## Max.   :5228  Max.   :82.00  Max.   :7.000  Max.   :4.0000  Max.   :4.5
##   rooms          heating          fuel          sewer
## Min. : 2.000  Length:1728          Length:1728          Length:1728

```

```

## 1st Qu.: 5.000   Class :character   Class :character   Class :character
## Median : 7.000   Mode  :character   Mode  :character   Mode  :character
## Mean   : 7.042
## 3rd Qu.: 8.250
## Max.   :12.000
##      waterfront      newConstruction      centralAir
##      Length:1728      Length:1728      Length:1728
##      Class :character  Class :character  Class :character
##      Mode  :character  Mode  :character  Mode  :character
##
##
```

Η μεταβλητή lotSize δίνεται σε εκτάρια και θα πρέπει να μετατραπεί σε square feet

```
lotSize=lotSize*43560
```

```

SH$fireplaces <- as.factor(SH$fireplaces)
SH$bedrooms <- as.factor(SH$bedrooms)
SH$bathrooms <- as.factor(SH$bathrooms)
SH$rooms <- as.factor(SH$rooms)
```

Εύρεση της δειγματικής διαμέσου για κάθε αριθμητική μεταβλητή του dataframe

```
sapply(Filter(is.numeric, SH), FUN = mean, na.rm = TRUE)
```

```

##      price      lotSize       age     landValue    livingArea   pctCollege
## 2.119667e+05 5.002141e-01 2.791609e+01 3.455719e+04 1.754976e+03 5.556771e+01
```

Τα ακόλουθα γραφήματα που δημιουργήθηκαν με τη βιβλιοθήκη ggplot() απεικονίζουν γραφικά τις μεταβλητές και τις μεταξύ τους σχέσεις.


```
library(ggplot2)
```

```
## Warning: package 'ggplot2' was built under R version 4.1.2
```

```

ggplot(SH, aes(x = price, fill = ..count..)) +
  geom_histogram(binwidth = 20000) +
  ggtitle("Histogram of House Price") +
  ylab("Frequency") +
  xlab("Housing Price") +
  theme(plot.title = element_text(hjust = 0.5))
```


Histogram of House Price



Στο πρώτο ιστόγραμμα φαίνεται η συχνότητα των σπιτιών συγκριτικά με την τιμή. όπως βλέπουμε και από το plot τα δεδομένα ακολουθούν Skewed Distribution - Η λοξή κατανομή η οποία είναι ασύμμετρη επειδή ένα φυσικό όριο αποτρέπει τα αποτελέσματα στη μία πλευρά.Ο συγκεκριμένος τύπος κατανομής μας δείχνει θετική ασυμμετρία στο δείγμα. Στην συγκεκριμένη περίπτωση φαίνεται οτι υπάρχει δεξιά λοξότητα καθώς το μεγαλύτερο πλήθος των σπιτιών έχουν αγοραστική αξία από 0 - 400.000, ενώ αρκετά λιγότερα έχουν αξία >400.000. Η κορυφή της διανομής είναι εκτός κέντρου προς το όριο και μια ουρά απλώνεται μακριά από αυτό.


```
ggplot(SH, aes(x = lotSize, fill = ..count..)) +
  geom_histogram(binwidth = 0.5) +
  ggtitle("Histogram of Lot Size") +
  ylab("Frequency") + xlab("Lot Size") +
  theme(plot.title = element_text(hjust = 0.5))
```

Histogram of Lot Size



```
ggplot(SH, aes(x = pctCollege, fill = ..count..)) +  
  geom_histogram(binwidth = 5) +  
  ggtitle("Histogram of percent of neighborhood that graduated college") +  
  ylab("Frequency") +  
  xlab("Percent of neighborhood that graduated college") +  
  theme(plot.title = element_text(hjust = 0.5))
```


Histogram of percent of neighborhood that graduated college



Το διάγραμμα για την ανεξάρτητη μεταβλητή pctCollege δείχνει το ποσοστό αποφοίτων κολεγίου της γειτονιάς. Το δείγμα ακολουθεί λοξή κατανομή από την δεξιά πλευρά ή αρνητικά λοξή κατανομή, έχοντας επίσης αρνητική ασυμετρία. Αυτή η συνθήκη προκύπτει καθώς οι μικρότερες τιμές του δείγματος έχουν λιγότερες πιθανότητες να εμφανιστούν. Πιο συγκεκριμένα είναι πολύ μικρό το ποσοστό (<30%) των γειτόνων που δεν έχουν αποφοιτήσει.

```
ggplot(SH, aes(x = livingArea, fill = ..count..)) + geom_histogram(binwidth = 200) + ggtitle("Histogram of livingArea")
```


Histogram of Living Area



Το τελευταίο ιστόγραμμα υποδεικνύει την σχέση της LivingArea με την συχνότητα ακολουθώντας λοξή κατανομή επίσης με θετική ασυμμετρία.

```
## `geom_smooth()` using formula 'y ~ x'  
ggplot(SH, aes(x = waterfront, fill = waterfront )) +  
  geom_bar() + ggtitle("Distribution of Waterfront") +  
  theme(plot.title = element_text(hjust = 0.5)) +  
  geom_text(stat='count', aes(label=..count..), vjust=-0.25)
```

Distribution of Waterfront




Το παραπάνω ραβδόγραμμα περιλαμβανει την κατανομή και δείχνει πόσα σπίτια στην Saratoga διαθέτουν προκυμαία - waterfront. Παρατηρείται οτι η πλειονότητα των σπιτιών δεν διαθέτει προκυμαία στο σπίτι του. Ο πίνακας συχνοτήτων και σχετικών συχνότητων σχετικά με το αν το σπίτι διαθέτει προκυμαία ή όχι

	Waterfront	Συχνότητα	Σχετική συχνότητα
1	Yes	15	0.9913
2	no	1713	0.008

Η κατανομή της μεταβλητής heating, φαίνεται παρακάτω.

```
ggplot(SH, aes(x = heating, fill = heating )) +
  geom_bar() + ggtitle("Distribution of Heating")+
  theme(plot.title = element_text(hjust = 0.5))+
  geom_text(stat='count',aes(label=..count..),vjust=-0.25)
```


Distribution of Heating



Η κατανομή της μεταβλητής centralAir, φαίνεται παρακάτω. Παρατηρούμε ότι η κατανομή αυτή ειναι περισσότερο κανονικοποιημένη καθώς οι τιμές του 'Έχω κεντρική θέρμανση' και του 'δεν εχω' δεν έχουν τόσο μεγάλη απόκλιση όσο προηγουμένως.

```
ggplot(SH, aes(x = centralAir, fill = centralAir )) +  
  geom_bar() + ggtitle("Distribution of Central Air") +  
  theme(plot.title = element_text(hjust = 0.5)) +  
  geom_text(stat='count', aes(label=..count..), vjust=-0.25)
```

Distribution of Central Air




Ο πίνακας συχνοτήτων και σχετικών συχνότητων σχετικά με το αν το σπίτι διαθέτει κεντρική θέρμανση

	CentralAir	Συχνότητα	Σχετική συχνότητα
1	Yes	635	0.632
2	no	1093	0.368

Η κατανομή για τα διάφορα είδη καυσίμου.

```
ggplot(SH, aes(x = fuel, fill = fuel )) +
  geom_bar() + ggtitle("Distribution of different Fuel type") +
  theme(plot.title = element_text(hjust = 0.5)) +
  geom_text(stat='count', aes(label=..count..), vjust=-0.25)
```




Η κατανομή για τα διάφορα είδη καυσίμου. Παρατηρούμε ότι τα περισσότερα παραδείγματα βρίσκονται στο feature:oil.

Ο πίνακας συχνοτήτων και σχετικών συχνότητων σχετικά με τις διαφορετικό τύπο θέρμανσης

	FuelType	Συχνότητα	Σχετική συχνότητα
1	electric	315	0.1822
2	gas	1197	0.6927
3	oil	216	0.125


Η παρακάτω κατανομή υποδυκνύει αν σπίτια διαθέτουν δημόσιο, ιδιωτικό υπόνομο. Πολύ μικρός ο αριθμός των αγνωστών παρατηρήσεων σε αυτή την μεταβλητή.

```
ggplot(SH, aes(x = sewer, fill = sewer )) +
  geom_bar() + ggtitle("Distribution of sewertype")+
  theme(plot.title = element_text(hjust = 0.5))+
  geom_text(stat='count',aes(label=..count..),vjust=-0.25)
```




Η μεταβλητή bedrooms δεν μπορούμε να απορρίψουμε οτι ακολουθεί κανονική κατανομή

```
ggplot(SH, aes(x = bedrooms, fill = bedrooms )) +
  geom_bar() + ggtitle("Distribution of bedrooms") +
  theme(plot.title = element_text(hjust = 0.5)) +
  geom_text(stat='count', aes(label=..count..), vjust=-0.25)
```



Ραβδόγραμμα για τον αριθμό των τζακιών


```
ggplot(SH, aes(x = fireplaces, fill = fireplaces )) +
  geom_bar() + ggtitle("Distribution of fireplaces") +
  theme(plot.title = element_text(hjust = 0.5)) +
  geom_text(stat='count', aes(label=..count..), vjust=-0.25)
```



Ραβδόγραμμα για τον αριθμό των bathrooms


```
ggplot(SH, aes(x = bathrooms, fill = bathrooms )) +
  geom_bar() + ggtitle("Distribution of bathrooms") +
  theme(plot.title = element_text(hjust = 0.5)) +
  geom_text(stat='count',aes(label=..count..),vjust=-0.25)
```

Distribution of bathrooms



Ραβδόγραμμα για τον αριθμό των δωματίων.

```
ggplot(SH, aes(x = rooms, fill = rooms )) +  
  geom_bar() + ggtitle("Distribution of bathrooms") +  
  theme(plot.title = element_text(hjust = 0.5)) +  
  geom_text(stat='count', aes(label=..count..), vjust=-0.25)
```



#Συσχέτιση μεταβλητών μεταξύ τους

```
library("ggcorrplot")
```

```
## Warning: package 'ggcorrplot' was built under R version 4.1.2
```

```
SHcor = data.frame(price, lotSize, age, landValue, livingArea, pctCollege, bedrooms, fireplaces, bathrooms)
correl = cor(SHcor)
round(correl, 2)
```


```
##          price lotSize   age landValue livingArea pctCollege bedrooms
## price      1.00   0.16 -0.19     0.58      0.71     0.20    0.40
## lotSize    0.16   1.00 -0.02     0.06      0.16    -0.03    0.11
## age       -0.19  -0.02  1.00    -0.02     -0.17    -0.04    0.03
## landValue   0.58   0.06 -0.02     1.00      0.42     0.23    0.20
## livingArea  0.71   0.16 -0.17     0.42      1.00     0.21    0.66
## pctCollege  0.20  -0.03 -0.04     0.23      0.21     1.00    0.16
## bedrooms   0.40   0.11  0.03     0.20      0.66     0.16    1.00
## fireplaces  0.38   0.09 -0.17     0.21      0.47     0.25    0.28
## bathrooms   0.60   0.08 -0.36     0.30      0.72     0.18    0.46
## rooms       0.53   0.14 -0.08     0.30      0.73     0.16    0.67
##          fireplaces bathrooms rooms
## price        0.38       0.60  0.53
## lotSize      0.09       0.08  0.14
## age        -0.17      -0.36 -0.08
```

```

## landValue      0.21      0.30  0.30
## livingArea    0.47      0.72  0.73
## pctCollege    0.25      0.18  0.16
## bedrooms      0.28      0.46  0.67
## fireplaces    1.00      0.44  0.32
## bathrooms     0.44      1.00  0.52
## rooms         0.32      0.52  1.00

```

```
ggcorrplot(correl, lab=TRUE)
```



#Συσχέτιση ανεξάρτητων μεταβλητών μεταξύ τους

Καύσιμο και τύπος Θέρμανσης (heating,fuel)

Υποθέτουμε ότι θα υπάρχει κάποια σχέση ανάμεσα στον τύπο του καυσίμου και στον τύπο θέρμανσης.

```
prop.table(table(heating,fuel),2)
```

```

##          fuel
## heating      electric      gas      oil
##   electric    0.946031746 0.005012531 0.004629630
##   hot air     0.050793651 0.802840434 0.666666667
##   hot water/steam 0.003174603 0.192147034 0.328703704

```

Φαίνεται πως υφίσταται συσχέτιση του fuel electric με τον τύπο θέρμανσης electric, του fuel gas με τον τύπο θέρμανσης ζεστού αέρα και του fuel oil με τον τύπο θέρμανσης ζεστού αέρα.

κεντρικός αερισμός και παραλία (centralAir,waterfront)

Θα εξετάσουμε αν υπάρχει συσχέτιση του centralAir με το waterfront.

```
prop.table(table(centralAir,waterfront),2)
```

```
##                  waterfront
## centralAir      No      Yes
##           No  0.6316404 0.7333333
##           Yes  0.3683596 0.2666667

x=as.matrix(c(64,36,73,27))
dim(x)=c(2,2)
fisher.test(x)

##
##  Fisher's Exact Test for Count Data
##
##  data:  x
##  p-value = 0.2232
##  alternative hypothesis: true odds ratio is not equal to 1
##  95 percent confidence interval:
##  0.3438828 1.2516078
##  sample estimates:
##  odds ratio
##  0.6589328
```

Από το Fisher's test προκύπτει ότι $p=0.22 > 0.05$ άρα η μηδενική υπόθεση δεν απορρίπτεται, δηλαδή οι μεταβλητές «centralAir» και «waterfront» είναι ανεξάρτητες (δεν έχουν σχέση).

Λοιπές αριθμητικές

Από τον πίνακα συσχέτισης φαίνεται ότι ισχυρή συσχέτιση μεταξύ τους έχουν οι ακόλουθες ανεξάρτητες αριθμητικές μεταβλητές: 1)οι rooms, bedrooms, bathrooms, fireplaces, livingArea (κάτι το οποίο είναι εύλογο αφού όλες έχουν σχέση με το μέγεθος του σπιτιού) 2)οι landValue με την livingArea


#Συσχέτιση ανεξάρτητων μεταβλητών με την εξαρτημένη

Δημιουργία scatterplots -μέσω της βιβλιοθήκης ggplot2 με σκοπό την οπτικοποίηση των σχεσεων της μεταβλητής price και των ανεξάρτητων μεταβλητών.

Price ~ Age

```
ggplot(SH, aes(x=age, y=price)) +
  geom_point(color='purple', size = 2) +
  geom_smooth(method=lm, color='#2C3E50')

## `geom_smooth()` using formula 'y ~ x'
```




Η συσχέτιση των δυο μεταβλήτων είναι αρκετά ισχυρή, καθώς υπάρχει αναλογική σταθερή μείωση των τιμών. Αυτό είναι λογικό, άμα λάβουμε υπόψιν ότι όσο πιο παλιό είναι το σπίτι τόσο και χαμηλότερη αγοραστική αξία θα έχει

Living Area ~ Price

```
ggplot(SH, aes(x=livingArea, y=price)) +
  geom_point(color='brown', size = 2) +
  geom_smooth(method=lm, color='#2C3E50')
```

```
## `geom_smooth()` using formula 'y ~ x'
```




Η living Area εχει τη μεγαλύτερη θετική συσχέτιση απο κάθε άλλη μεταβλητή, καθώς ο ρυθμός με τον οποίο αυξάνονται οι τιμές των δειγμάτων ειναι παραπλήσιος.

pctCollege - price

```
ggplot(SH, aes(x=pctCollege, y=price)) +
  geom_point(color='grey', size = 2) +
  geom_smooth(method=lm, color='#2C3E50')

## `geom_smooth()` using formula 'y ~ x'
```




Οι παρατηρήσεις του δείγματος εχουν μεγάλη διασπορά, το οποίο μας δείχνει ότι οι δεν μεταβλητές δεν έχουν ισχυρή συσχέτιση.

landValue - price

```
ggplot(SH, aes(x=landValue, y=price)) +
  geom_point(color='brown', size = 2) +
  geom_smooth(method=lm, color='#2C3E50')
```

```
## `geom_smooth()` using formula 'y ~ x'
```




οι δύο μεταβλητές φαίνεται οτι έχουν συσχέτιση καθώς όσο αυξανεται το landValue, τείναι να αυξάνεται και η τιμή του σπιτιού. Οι περισσότερες παρατηρήσεις βρίσκονται στο διάστημα 0 - 100.000.

Θηκόγραμμα μεταξύ των μεταβλητών price-bedrooms

```
ggplot(SH, aes(x=bedrooms, y=price, fill=bedrooms)) +
  geom_boxplot(alpha=0.3) +
  stat_summary(fun.y=mean, geom="point", shape=20, size=4, color="red", fill="red")+
  ggtitle("Boxplot of House Price by Bedrooms")+
  theme(plot.title = element_text(hjust = 0.5))
```

Warning: `fun.y` is deprecated. Use `fun` instead.

Boxplot of House Price by Bedrooms



Για τον αριθμό υπνοδωματίων:1 φαίνεται οτι υπάρχει θετική ασυμμετρία όπου η διάμεσος(το 50%-ποσοστιμόριο) πλησιάζει περισσότερο το πρώτο τεταρτημόριο(25%-ποσοστιμόριο) δηλαδή οι περισσότερες τιμές της μεταβλητής κατανέμονται ανάμεσα στην διάμεσο και το τρίτο τεταρτημόριο.

Για τον αριθμό υπνοδωματίων:6 φαίνεται οτι υπάρχει αρνητική ασυμμετρία όπου η διάμεσος(το 50%-ποσοστιμόριο) πλησιάζει περισσότερο το τρίτο τεταρτημόριο(75%-ποσοστιμόριο) δηλαδή οι περισσότερες τιμές της μεταβλητής κατανέμονται ανάμεσα στην διάμεσο και το πρώτο τεταρτημόριο.

Στις υπόλοιπες περιπτώσεις το δείγμα ακολουθεί κανονική κατανομή


Για τις περιπτώσεις των υπνοδωματίων 2,3,4,5,7 υπάρχουν αρκετές εξωτερικές τιμές(παράτυπα σημεία), γεγονός που φανερώνει οτι δεν έχει τόσο σωστή δειγματοληψία ωστε το δείγμα να ειναι ανταπροσωπευτικό για τον πληθυσμό.

Θηκόγραμμα μεταξύ των μεταβλητών price-bathrooms

```
ggplot(SH, aes(x=bathrooms, y=price, fill=bathrooms)) +
  geom_boxplot(alpha=0.3) +
  stat_summary(fun.y=mean, geom="point", shape=20, size=4, color="red", fill="red")+
  ggtitle("Boxplot of House Price by Bathrooms")+
  theme(plot.title = element_text(hjust = 0.5))
```

Warning: `fun.y` is deprecated. Use `fun` instead.

Boxplot of House Price by Bedrooms



Για τον αριθμό μπάνιων: 3.5 φαίνεται οτι υπάρχει θετική ασυμμετρία όπου η διάμεσος(το 50%-ποσοστιμόριο) πλησιάζει περισσότερο το πρώτο τεταρτημόριο(25%-ποσοστιμόριο) δηλαδή οι περισσότερες τιμές της μεταβλητής κατανέμονται ανάμεσα στην διάμεσο και το τρίτο τεταρτημόριο.

Επιπλέον, παρατηρούμε οτι όσο περισσότερα μπάνια διαθέτει ένα σπίτι, τόσο μεγαλύτερη είναι και η τιμή του σπιτιού.

Για τις περιπτώσεις των σπιτιών που έχουν τόσα μπάνια 1 - 3.5 υπάρχουν αρκετές εξωτερικές τιμές(παράτυπα σημεία), γεγονός που φανερώνει οτι δεν έχει τόσο σωστή δειγματοληψία ωστε το δείγμα να είναι ανταπροσωπευτικό για τον πληθυσμό.

Μοντέλα με εξαρτημένη μεταβλητή την τιμή

Παρατηρούμε ότι υπάρχει ισχυρή θετική συσχέτιση της τιμής με τον αριθμό δωματίων, υπνοδωματίων μπάνιων, εμβαδού σπιτιού, αξίας οικοπέδου. Οι παρατηρήσεις αυτές θα είναι πολύ χρήσιμες για την ακόλουθη σχεδίαση των μοντέλων.

Θα σχεδιάσουμε 3 μοντέλα με εξαρτημένη μεταβλητή την τιμή: ένα με όλες τις ανεξάρτητες αριθμητικές, ένα με μόνο κατηγορικές και ένα και με αριθμητικές και με κατηγορικές.

#1o Μοντέλα με εξαρτημένη μεταβλητή την price (all numeric) Στο πρώτο μοντέλο με μόνο numerical μεταβλητές θα επιλέξουμε τις 3 με το μεγαλύτερο correlation με την τιμή. Θα ξεκινήσουμε με έλεγχο των κυρίων επιδράσεων, όλων των αλληλεπιδράσεων 2ης τάξης και την αλληλεπίδραση 3ης τάξης.

```
model1=lm(price ~ livingArea*landValue*bathrooms)
summary(model1)
```

```

## 
## Call:
## lm(formula = price ~ livingArea * landValue * bathrooms)
## 
## Residuals:
##      Min       1Q   Median       3Q      Max 
## -217304  -35694   -6357  27271  437889 
## 
## Coefficients:
##                               Estimate Std. Error t value Pr(>|t|)    
## (Intercept)          6.669e+04  1.752e+04   3.806 0.000146 ***
## livingArea           3.664e+01  1.098e+01   3.336 0.000867 *** 
## landValue            7.071e-01  3.407e-01   2.076 0.038063 *  
## bathrooms           -1.379e+04  9.450e+03  -1.459 0.144760    
## livingArea:landValue 3.411e-05  1.731e-04   0.197 0.843843    
## livingArea:bathrooms 2.022e+01  4.737e+00   4.269 2.07e-05 *** 
## landValue:bathrooms  3.807e-01  1.678e-01   2.269 0.023405 *  
## livingArea:landValue:bathrooms -1.288e-04  6.513e-05  -1.978 0.048046 * 
## --- 
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1 
## 
## Residual standard error: 60410 on 1720 degrees of freedom
## Multiple R-squared:  0.625, Adjusted R-squared:  0.6234 
## F-statistic: 409.5 on 7 and 1720 DF, p-value: < 2.2e-16

```

Παρατηρούμε ότι $p<0.001<0.05$ και επομένως το μοντέλο συνεισφέρει σημαντικά στην ερμηνεία της εξαρτημένης μεταβλητής. Επίσης εξηγεί το (R-squared) 62,5% της μεταβλητότητας της εξαρτημένης μεταβλητής (price). Οι συντελεστές livingArea, landValue, η αλληλεπίδραση των δύο με την bathrooms καθώς και η τριπλή αλληλεπίδραση τους είναι στατιστικά σημαντικοί αφού έχουν $p<0.001<0.05$ και επομένως συνεισφέρουν στην ερμηνεία της εξαρτημένης μεταβλητής. Αντίθετα η bathrooms και η αλληλεπίδραση των livingArea και landValue δεν είναι στατιστικά σημαντικές (έχουν $p>0.05$) και επομένως μπορουν να αφαιρεθούν από το μοντέλο.

```

model2=update(model1, ~. -bathrooms -livingArea:landValue)
anova(model1,model2)

```

```

## Analysis of Variance Table
## 
## Model 1: price ~ livingArea * landValue * bathrooms
## Model 2: price ~ livingArea + landValue + livingArea:bathrooms + landValue:bathrooms +
##           livingArea:landValue:bathrooms
## 
##   Res.Df   RSS Df Sum of Sq    F Pr(>F)    
## 1    1720 6.2766e+12
## 2    1722 6.2853e+12 -2 -8713385517 1.1939 0.3033

```

```

model3=update(model2, ~. -landValue:bathrooms)
summary(model3)

```

```

## 
## Call:
## lm(formula = price ~ livingArea + landValue + livingArea:bathrooms +
##     livingArea:landValue:bathrooms)

```

```

## 
## Residuals:
##      Min       1Q   Median       3Q      Max
## -217260  -35683   -5975  27709  437600
## 
## Coefficients:
##                               Estimate Std. Error t value Pr(>|t|)
## (Intercept)               4.978e+04  6.315e+03   7.882 5.68e-15 ***
## livingArea                 3.824e+01  6.111e+00   6.259 4.89e-10 ***
## landValue                  1.203e+00  8.406e-02  14.312 < 2e-16 ***
## livingArea:bathrooms      1.691e+01  1.739e+00   9.721 < 2e-16 ***
## livingArea:landValue:bathrooms -4.901e-05  1.285e-05  -3.814 0.000141 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
## 
## Residual standard error: 60470 on 1723 degrees of freedom
## Multiple R-squared:  0.6235, Adjusted R-squared:  0.6226
## F-statistic: 713.4 on 4 and 1723 DF,  p-value: < 2.2e-16

```

```
anova(model2,model3)
```

```

## Analysis of Variance Table
## 
## Model 1: price ~ livingArea + landValue + livingArea:bathrooms + landValue:bathrooms +
##           livingArea:landValue:bathrooms
## Model 2: price ~ livingArea + landValue + livingArea:bathrooms + livingArea:landValue:bathrooms
## 
## Res.Df      RSS Df Sum of Sq    F Pr(>F)
## 1     1722 6.2853e+12
## 2     1723 6.3008e+12 -1 -1.5531e+10 4.2551 0.03928 *
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

```

```
model4=update(model3, ~. -livingArea:landValue:bathrooms)
anova(model1,model2)
```

```

## Analysis of Variance Table
## 
## Model 1: price ~ livingArea * landValue * bathrooms
## Model 2: price ~ livingArea + landValue + livingArea:bathrooms + landValue:bathrooms +
##           livingArea:landValue:bathrooms
## 
## Res.Df      RSS Df Sum of Sq    F Pr(>F)
## 1     1720 6.2766e+12
## 2     1722 6.2853e+12 -2 -8713385517 1.1939 0.3033

```

```
summary(model4)
```

```

## 
## Call:
## lm(formula = price ~ livingArea + landValue + livingArea:bathrooms)
## 
## Residuals:
##      Min       1Q   Median       3Q      Max
## -217260  -35683   -5975  27709  437600
## 
```


```


## -235866   -35095    -5845     26977   453197
##
## Coefficients:
##                               Estimate Std. Error t value Pr(>|t|)
## (Intercept)           5.730e+04  6.023e+03   9.513 < 2e-16 ***
## livingArea            4.102e+01  6.091e+00   6.734 2.25e-11 ***
## landValue             9.346e-01  4.612e-02  20.265 < 2e-16 ***
## livingArea:bathrooms 1.389e+01  1.555e+00   8.933 < 2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 60710 on 1724 degrees of freedom
## Multiple R-squared:  0.6203, Adjusted R-squared:  0.6197
## F-statistic: 938.9 on 3 and 1724 DF,  p-value: < 2.2e-16


```


Παρατηρούμε ότι τα μοντέλα 1,2,3 δεν έχουν στατιστικά σημαντική διαφορά μεταξύ τους ενώ το μοντέλο 3 με το 4 έχουν στατιστικά σημαντική διαφορά ($p<0.001$). Ωστόσο το μοντέλο 4 ίσως να είναι προτιμητέο καθώς είναι λιγότερο περίπλοκο (αφού έχει αφαιρεθεί και η τριπλή αλληλεπίδραση παρά το ότι είναι στατιστικά σημαντική) και εξακολουθεί να συνεισφέρει σημαντικά στην ερμηνεία της εξαρτημένης μεταβλητής και να εξηγεί το (R-squared) σε παραπλήσιο βαθμό (62%) την μεταβλητότητας της εξαρτημένης μεταβλητής(price).

```
plot(model4)
```









Παρατηρούμε ότι υφίσταται κάπτοι pattern στα υπόλοιπα (ύπαρξη ετεροσκεδαστικότητας). Ακόμα η κατανομή τους ξεφεύγει από την κανονική (QQplot). Θα πειραματιστούμε λοιπόν με το λογαριθμικό μετασχηματισμό της εξαρτημένης μεταβλητής και των livingArea και landValue.

```
model5=lm(log(price) ~ log(livingArea) + log(landValue) + livingArea:bathrooms)
```

Το πρόβλημα της ετεροσκεδαστικότητας έχει αντιμετωπιστεί και η κατανομή των καταλοίπων είναι σημαντικά βελτιωμένη, προσεγγίζοντας την κανονική. Σε όλα τα σχήματα φαίνεται πως η παρατήρηση #1011 έχει άσχημη επίδραση στην παλινδρόμηση και επομένως στο τελικό μοντέλο θα αφαιρεθεί.

```
model6=lm(log(price) ~ log(livingArea) + log(landValue) + livingArea:bathrooms, subset=(1:length(price))
summary(model6)
```


```
##
## Call:
## lm(formula = log(price) ~ log(livingArea) + log(landValue) +
##     livingArea:bathrooms, subset = (1:length(price) != 1011))
##
## Residuals:
##      Min       1Q   Median       3Q      Max 
## -2.50429 -0.16588  0.00001  0.16933  1.50013 
## 
## Coefficients:
##             Estimate Std. Error t value Pr(>|t|)    
## (Intercept) 7.477e+00  2.847e-01  26.262   <2e-16 ***
```


```


## log(livingArea)      4.440e-01  4.101e-02  10.827   <2e-16 ***
## log(landValue)       1.211e-01  7.385e-03  16.393   <2e-16 ***
## livingArea:bathrooms 5.165e-05  5.881e-06   8.781   <2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 0.2885 on 1723 degrees of freedom
## Multiple R-squared:  0.5793, Adjusted R-squared:  0.5785
## F-statistic: 790.8 on 3 and 1723 DF,  p-value: < 2.2e-16


plot(model6)

```









Παρατηρούμε ότι το τελικό μοντέλο έχει στατιστικά σημαντική ερμηνευτική ισχύ της τιμής των σπιτιών (εξαρτημένη μεταβλητή), και καλή εξήγηση της μεταβλητότητας της (~58%). Και οι τρεις όροι είναι στατιστικά σημαντικοί και οι θετικοί συντελεστές στην livingArea, στην landValue και στην αλληλεπίδραση των livingArea και bathrooms, σημαίνει ότι όταν έχουμε αύξηση στους 3 όρους κατά μια μονάδα ασκείται ανάλογη με τη συντελεστή αυξητική συνιστώσα στην τιμή.

#2o Μοντέλα με εξαρτημένη μεταβλητή την price (all categorical)

Διερευνήσαμε την ανάλυση διακύμανσης για όλες τις κατηγορικές μεταβλητές μας (heating, fuel, sewer, waterfront, newConstruction, centralAir) αλλά και για τις numeric που μπορούν να εκληφθούν ως ordinal (rooms, bedrooms, fireplace, bathrooms) και βρέθηκε στατιστικά σημαντική επίδραση όλων των παραγόντων στην τιμή.

Ενδεικτικά:

Δωμάτια - rooms

```
library("DescTools")

## Warning: package 'DescTools' was built under R version 4.1.2

rooms3=as.factor(rooms)
model30=aov(price~rooms3)
summary(model30)
```

```

##          Df    Sum Sq   Mean Sq F value Pr(>F)
## rooms3      10 5.233e+12 5.233e+11   78.12 <2e-16 ***
## Residuals  1717 1.150e+13 6.699e+09
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

```

```
PostHocTest(model30)
```

```

##
## Posthoc multiple comparisons of means : Tukey HSD
## 95% family-wise confidence level
##
## $rooms3
##          diff      lwr.ci     upr.ci    pval
## 3-2     39656.225 -149196.8398 228509.29 0.99986
## 4-2     74417.724 -113145.7908 261981.24 0.97236
## 5-2     72797.610 -114572.7677 260167.99 0.97621
## 6-2     90813.660 -96475.7845 278103.10 0.89760
## 7-2     97328.980 -89817.3745 284475.34 0.84776
## 8-2    126096.814 -61160.5586 313354.19 0.52646
## 9-2    150778.796 -37066.0047 338623.60 0.25619
## 10-2   194067.206   6213.1538 381921.26 0.03590 *
## 11-2   211413.736   22304.9460 400522.53 0.01433 *
## 12-2   278718.818   89776.0441 467661.59 0.00011 ***
## 4-3     34761.499    -655.6075 70178.61 0.05977 .
## 5-3     33141.385   -1238.2288 67521.00 0.07045 .
## 6-3     51157.435   17221.6805 85093.19 6.9e-05 ***
## 7-3     57672.755   24535.8037 90809.71 1.3e-06 ***
## 8-3     86440.589   52682.2860 120198.89 3.9e-12 ***
## 9-3    111122.571   74244.8201 148000.32 3.9e-12 ***
## 10-3   154410.981   117486.1350 191335.83 3.8e-12 ***
## 11-3   171757.511   128903.8773 214611.14 3.8e-12 ***
## 12-3   239062.593   196947.6157 281177.57 3.8e-12 ***
## 5-4    -1620.114   -28012.3426 24772.11 1.00000
## 6-4     16395.936   -9415.4437 42207.32 0.61541
## 7-4    22911.257   -1840.5003 47663.01 0.09936 .
## 8-4     51679.090   26101.4648 77256.72 5.3e-09 ***
## 9-4     76361.072   46788.1047 105934.04 3.9e-12 ***
## 10-4   119649.482   90017.8074 149281.16 3.8e-12 ***
## 11-4   136996.012   100239.7090 173752.32 3.8e-12 ***
## 12-4   204301.094   168408.7104 240193.48 3.8e-12 ***
## 6-5     18016.050   -6352.2438 42384.34 0.37824
## 7-5     24531.370    1288.3956 47774.35 0.02845 *
## 8-5     53299.204   29178.6458 77419.76 9.0e-11 ***
## 9-5     77981.186   49658.9895 106303.38 3.9e-12 ***
## 10-5   121269.596   92886.1051 149653.09 3.8e-12 ***
## 11-5   138616.126   102858.4383 174373.81 3.8e-12 ***
## 12-5   205921.208   171052.1728 240790.24 3.8e-12 ***
## 7-6     6515.320   -16065.9434 29096.58 0.99769
## 8-6     35283.154   11799.5655 58766.74 7.4e-05 ***
## 9-6     59965.136   32183.4079 87746.86 2.8e-10 ***
## 10-6   103253.546   75409.3337 131097.76 3.8e-12 ***
## 11-6   120600.076   85268.9306 155931.22 3.8e-12 ***
## 12-6   187905.158   153473.6721 222336.64 3.8e-12 ***


```

```

## 8-7    28767.834    6454.1369   51081.53  0.00170 ** 
## 9-7    53449.815    26649.6934   80249.94  9.2e-09 *** 
## 10-7   96738.225    69873.3360  123603.11  3.8e-12 *** 
## 11-7   114084.756    79520.1499  148649.36  3.9e-12 *** 
## 12-7   181389.838    147745.3826  215034.29  3.8e-12 *** 
## 9-8     24681.982    -2882.7056   52246.67  0.12825 
## 10-8   67970.392     40342.7293   95598.05  4.1e-12 *** 
## 11-8   85316.922     50156.1851  120477.66  4.4e-12 *** 
## 12-8   152622.004    118365.4016  186878.61  3.8e-12 *** 
## 10-9   43288.410     11925.4826   74651.34  0.00047 *** 
## 11-9   60634.940     22469.2108   98800.67  1.8e-05 *** 
## 12-9   127940.022    90605.5838  165274.46  3.8e-12 *** 
## 11-10  17346.530    -20864.7068   55557.77  0.93159 
## 12-10  84651.613     47270.6543  122032.57  2.8e-11 *** 
## 12-11  67305.082     24057.8192  110552.34  3.1e-05 *** 
## 
## --- 
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

```

```
boxplot(price~rooms3)
```



Η ανάλυση διακύμανσης δείχνει στατιστικά σημαντική επίδραση του παράγοντα rooms στην τιμή ($p<0,001$). Ο Post hoc έλεγχος Tukey HSD δείχνει ότι δεν υπάρχει διαφορά ως προς την τιμή ανάμεσα στον αριθμό δωματίων 1 έως 6, 7 με 8, 9 με 10. Επομένως μπούμε να χωρίσουμε τον παράγοντα στις κατηγορίες: μεχρι6, 7ή8, 9ή10, 11. Το παραπάνω συμπέρασμα γίνεται και οπτικά κατανοητό από το σχετικό boxplot.

```

levels(rooms3)[c(1:6)] = "6orLess"
levels(rooms3)[c(2:3)] = "7or8"
levels(rooms3)[c(3:4)] = "9or10"
model30=aov(price~rooms3)
summary.aov(model30)


```

```

##          Df      Sum Sq   Mean Sq F value Pr(>F)
## rooms3      3 4.886e+12 1.629e+12     237 <2e-16 ***
## Residuals 1724 1.185e+13 6.873e+09
## ---
## Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

```

```
boxplot(price~rooms3)
```



```
PostHocTest(model30)
```

```

##
## Posthoc multiple comparisons of means : Tukey HSD
## 95% family-wise confidence level
##
## $rooms3
##           diff      lwr.ci      upr.ci    pval
## 7or8-6orLess 52978.1  40431.40  65524.80 4.3e-12 ***
## 9or10-6orLess 118050.0 102013.16 134086.85 4.3e-12 ***

```

```

## 12-6orLess    196838.0 171657.05 222018.96 4.3e-12 ***
## 9or10-7or8     65071.9  46988.12  83155.68 4.3e-12 ***
## 12-7or8      143859.9 117328.35 170391.45 4.3e-12 ***
## 12-9or10      78788.0  50438.68 107137.32 1.2e-11 ***
##
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

summary.lm(model30)

## 
## Call:
## aov(formula = price ~ rooms3)
##
## Residuals:
##   Min     1Q Median     3Q    Max
## -294719 -52364 -13531  38612 545641
##
## Coefficients:
##             Estimate Std. Error t value Pr(>|t|)
## (Intercept) 176381     2573    68.54 <2e-16 ***
## rooms37or8   52978     4879    10.86 <2e-16 ***
## rooms39or10  118050    6236    18.93 <2e-16 ***
## rooms312     196838    9792    20.10 <2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 82910 on 1724 degrees of freedom
## Multiple R-squared:  0.292, Adjusted R-squared:  0.2907
## F-statistic:  237 on 3 and 1724 DF, p-value: < 2.2e-16

```

Η ανάλυση διακύμανσης του απλοποιημένου και βελτιωμένου μοντέλου εξακολουθεί δείχνει στατιστικά σημαντική επίδραση του παράγοντα rooms στην τιμή ($p<0,001$). Από το PostHocTest βλέπουμε ότι όλα τα επίπεδα έχουν στατιστικά σημαντική διαφορά μεταξύ τους καθώς και την διαφορά που παρατηρείται στη μέση τιμή του σπιτιού όταν τα δωμάτια αυξάνονται από το κάθε επίπεδο στο άλλο (ενδεικτικά όταν τα δωμάτια αυξάνονται από το επίπεδο των '6orLess' στα '11' η μέση τιμή των σπιτιών αυξάνεται κατά 196.838).

Τζάκια - fireplaces

```

fireplaces=factor(fireplaces)
model35=aov(price~fireplaces)
summary(model35)


##           Df Sum Sq Mean Sq F value Pr(>F)
## fireplaces     4 2.537e+12 6.343e+11   76.97 <2e-16 ***
## Residuals   1723 1.420e+13 8.241e+09
##
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

```

```
PostHocTest(model35)
```

```
##  
## Posthoc multiple comparisons of means : Tukey HSD  
## 95% family-wise confidence level  
##  
## $fireplaces  
##      diff      lwr.ci     upr.ci    pval  
## 1-0  60509.59  48333.12  72686.07 3.3e-12 ***  
## 2-0 144168.01 104848.07 183487.94 3.4e-12 ***  
## 3-0 185846.65 10328.90 361364.40  0.0317 *  
## 4-0 525346.65 349828.90 700864.40 3.4e-12 ***  
## 2-1  83658.42  44565.56 122751.27 6.1e-08 ***  
## 3-1 125337.06 -50129.96 300804.07  0.2911  
## 4-1 464837.06 289370.04 640304.07 1.0e-11 ***  
## 3-2  41678.64 -137727.22 221084.51  0.9695  
## 4-2 381178.64 201772.78 560584.51 7.8e-08 ***  
## 4-3 339500.00  91615.18 587384.82  0.0018 **  
##  
## ---  
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```
boxplot(price~fireplaces)
```




Η ανάλυση διακύμανσης δείχνει στατιστικά σημαντική επίδραση του παράγοντα fireplaces στην τιμή ($p<0,001$). Ο Post hoc έλεγχος Tukey HSD δείχνει ότι δεν υπάρχει διαφορά ως προς την τιμή ανάμεσα

στον αριθμό τζακιών από 1 έως 3. Επομένως μπούμε να χωρίσουμε τον παράγοντα στις κατηγορίες: 0, 1-3, 4. Το παραπάνω συμπέρασμα γίνεται και οπτικά κατανοητό από το σχετικό boxplot.

```
levels(fireplaces)[c(2:4)] = "1-3"
model35=aov(price~fireplaces)
summary.aov(model35)
```

```
##           Df   Sum Sq  Mean Sq F value Pr(>F)
## fireplaces     2 2.226e+12 1.113e+12   132.3 <2e-16 ***
## Residuals    1725 1.451e+13 8.411e+09
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```
boxplot(price~fireplaces)
```



```
PostHocTest(model35)
```

```
##
## Posthoc multiple comparisons of means : Tukey HSD
## 95% family-wise confidence level
##
## $fireplaces
##      diff    lwr.ci   upr.ci   pval
## 1-3-0 64327.37 53863.84 74790.9 5.2e-12 ***
```

```

## 4-0    525346.65 373017.45 677675.8 5.3e-12 ***
## 4-1-3  461019.28 308741.31 613297.3 1.1e-11 ***
##
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

summary.lm(model35)

##
## Call:
## aov(formula = price ~ fireplaces)
##
## Residuals:
##     Min      1Q  Median      3Q     Max 
## -233981 -58981 -18653   42329  585347 
##
## Coefficients:
##             Estimate Std. Error t value Pr(>|t|)    
## (Intercept) 174653     3372   51.80 < 2e-16 ***
## fireplaces1-3 64327     4461   14.42 < 2e-16 ***
## fireplaces4  525347     64939    8.09 1.11e-15 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 91710 on 1725 degrees of freedom
## Multiple R-squared:  0.133, Adjusted R-squared:  0.132 
## F-statistic: 132.3 on 2 and 1725 DF,  p-value: < 2.2e-16

```

Η ανάλυση διακύμανσης του απλοποιημένου και βελτιωμένου μοντέλου εξακολουθεί δείχνει στατιστικά σημαντική επίδραση του παράγοντα fireplaces στην τιμή ($p<0,001$). Από το PostHocTest βλέπουμε ότι όλα τα επίπεδα έχουν στατιστικά σημαντική διαφορά μεταξύ τους καθώς και την διαφορά που παρατηρείται στη μέση τιμή του σπιτιού όταν τα τζάκια αυξάνονται από το κάθε επίπεδο στο άλλο (ενδεικτικά όταν τα τζάκια αυξάνονται από το επίπεδο των '0' στα '4' η μέση τιμή των σπιτιών αυξάνεται κατά 525.347).

Τύπος θέρμανσης - heating

Παρατηρούμε ότι η μεταβλητή heating έχει στατιστικά σημαντική επίδραση στην τιμή ($p<0,001$) όμως χαμηλή ερμηνευτική ισχύ της μεταβλητότητας της τιμής ($R-squared= 5,97\%$). Από το PostHocTest βλέπουμε ότι όλα τα επίπεδα της μεταβλητής έχουν στατιστικά σημαντική διαφορά μεταξύ τους ως προς την τιμή. Από την ανάλυση του μοντέλου βλέπουμε την διαφορά που παρατηρείται στη μέση τιμή του σπιτιού όταν αλλάζει ο τύπος της θέρμανσης (ενδεικτικά όταν ο τύπος της θέρμανσης γίνεται από 'electric' 'hot air' η μέση τιμή των σπιτιών αυξάνεται κατά 64.467). Τα παραπάνω φαίνονται καθαρά και στο boxplot (όπου φαίνεται και η ύπαρξη πολλών outliers).

Νεόδμητο - newConstruction

```

model41=aov(price~newConstruction)
summary.lm(model41)

```

```

## 
## Call:
## aov(formula = price ~ newConstruction)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -203507  -64632  -21007  41493  566493
##
## Coefficients:
##                               Estimate Std. Error t value Pr(>|t|)
## (Intercept)            208507     2396  87.034 < 2e-16 ***
## newConstructionYes    73800      11065   6.669 3.45e-11 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 97230 on 1726 degrees of freedom
## Multiple R-squared:  0.02512, Adjusted R-squared:  0.02456
## F-statistic: 44.48 on 1 and 1726 DF, p-value: 3.446e-11

# plot(newConstruction, price)

```

Παρατηρούμε ότι η μεταβλητή newConstruction έχει στατιστικά σημαντική επίδραση στην τιμή ($p<0.001$) όμως πολύ χαμηλή ερμηνευτική ισχύ της μεταβλητότητας της τιμής($R\text{-squared}=2,5\%$). Δηλαδή η μέση τιμή των νέων σπιτιών είναι στατιστικά σημαντικά υψηλότερη αλλά η διακυμάνσεις στην τιμή πολύ λίγο οφείλονται στο αν είναι νέο το σπίτι. Συγκεκριμένα βλέπουμε ότι η διαφορά που παρατηρείται στη μέση τιμή του σπιτιού όταν αυτό είναι νεόδμητο είναι 73.800. Τα παραπάνω φαίνονται καθαρά και στο boxplot (όπου φαίνεται και η ύπαρξη πολλών outliers στα παλαιά σπίτια και καθόλου στα νέα).

Ωστόσο όπως δείχθηκε παραπάνω πολλές από τις μεταβλητές αυτές έχουν συσχέτιση μεταξύ τους (collinearity) και επομένως δε θα χρειαστούν όλες στο τελικό μοντέλο.

#3ο Μοντέλα με εξαρτημένη μεταβλητή την price (numerical & categorical) Για το επόμενο μοντέλο θα λάβουμε υπόψη τη συμμεταβλητότητα των παραγόντων και θα επιλέξουμε να συμπεριλάβουμε αυτές με χαμηλό collinearity, επιλέγοντας μία συνεχή numerical (την landValue) μία διακριτή numerical που μπορεί να μετατραπεί σε Ordinal (την fireplaces) μία categorical (την heating) και μία binary (την centralAir) Θα ακολουθήσουμε διαδικασία ANCOVA σχηματίζοντας το μοντέλο με κύριες επιδράσεις και αλληλεπιδράσεις 2ης τάξης.

```

model16= aov(price~ landValue +fireplaces +heating +centralAir +landValue:fireplaces+heating:centralAir
summary.lm(model16)

```

```

## 
## Call:
## aov(formula = price ~ landValue + fireplaces + heating + centralAir +
##       landValue:fireplaces + heating:centralAir + landValue:heating +
##       centralAir:fireplaces + landValue:centralAir + fireplaces:heating)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -273177  -47378   -9078   34409  428709
##
## Coefficients: (3 not defined because of singularities)
##                               Estimate Std. Error t value Pr(>|t|)
## (Intercept)           1.082e+05  7.711e+03 14.028 < 2e-16 ***

```

```

## landValue          2.320e+00  3.310e-01  7.010 3.43e-12 ***
## fireplaces1-3    2.173e+04  9.627e+03  2.257 0.024130 *
## fireplaces4       8.492e+05  2.197e+05  3.865 0.000115 ***
## heatinghot air    2.463e+04  8.679e+03  2.838 0.004600 **
## heatinghot water/steam 2.928e+04  1.093e+04  2.679 0.007454 **
## centralAirYes     -9.141e+03  1.310e+04  -0.698 0.485367
## landValue:fireplaces1-3 -1.381e-01  1.217e-01  -1.134 0.256749
## landValue:fireplaces4   -4.773e+00  2.224e+00  -2.146 0.031974 *
## heatinghot air:centralAirYes 3.434e+04  1.276e+04  2.692 0.007171 **
## heatinghot water/steam:centralAirYes 3.550e+04  1.922e+04  1.848 0.064838 .
## landValue:heatinghot air   -9.331e-01  3.220e-01  -2.898 0.003805 **
## landValue:heatinghot water/steam -1.126e+00  3.400e-01  -3.313 0.000942 ***
## fireplaces1-3:centralAirYes -4.934e+02  8.859e+03  -0.056 0.955592
## fireplaces4:centralAirYes           NA        NA        NA        NA
## landValue:centralAirYes      1.883e-01  1.254e-01  1.502 0.133344
## fireplaces1-3:heatinghot air  2.248e+04  1.074e+04  2.093 0.036533 *
## fireplaces4:heatinghot air           NA        NA        NA        NA
## fireplaces1-3:heatinghot water/steam 2.647e+04  1.296e+04  2.043 0.041178 *
## fireplaces4:heatinghot water/steam           NA        NA        NA        NA
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 73640 on 1711 degrees of freedom
## Multiple R-squared:  0.4456, Adjusted R-squared:  0.4404
## F-statistic: 85.96 on 16 and 1711 DF,  p-value: < 2.2e-16

```

```
summary(model16)
```

	Df	Sum Sq	Mean Sq	F value	Pr(>F)						
## landValue	1	5.655e+12	5.655e+12	1042.772	< 2e-16 ***						
## fireplaces	2	1.181e+12	5.906e+11	108.914	< 2e-16 ***						
## heating	2	1.923e+11	9.617e+10	17.735	2.38e-08 ***						
## centralAir	1	2.564e+11	2.564e+11	47.288	8.56e-12 ***						
## landValue:fireplaces	2	2.329e+10	1.164e+10	2.147	0.11711						
## heating:centralAir	2	4.501e+10	2.251e+10	4.150	0.01592 *						
## landValue:heating	2	6.577e+10	3.288e+10	6.064	0.00237 **						
## fireplaces:centralAir	1	6.843e+07	6.843e+07	0.013	0.91057						
## landValue:centralAir	1	1.053e+10	1.053e+10	1.942	0.16367						
## fireplaces:heating	2	2.862e+10	1.431e+10	2.639	0.07173 .						
## Residuals	1711	9.278e+12	5.423e+09								
## ---											
## Signif. codes:	0	'***'	0.001	'**'	0.01	'*'	0.05	.	0.1	' '	1

Παρατηρούμε ότι $p<0.001<0.05$ και επομένως το μοντέλο συνεισφέρει σημαντικά στην ερμηνεία της εξαρτημένης μεταβλητής. Επίσης εξηγεί το (R-squared) 45% της μεταβλητότητας της εξαρτημένης μεταβλητής(price). Οι συντελεστές landValue, fireP, heating, centralAir, οπως και η αλληλεπίδραση των landValue με την heating είναι στατιστικά σημαντικοί αφού έχουν $p<0.001<0.05$ και επομένως συνεισφέρουν στην ερμηνεία της εξαρτημένης μεταβλητής. Επίσης σημαντική είναι η αλληλεπίδραση των heating και centralAir ($p=0.015<0.05$). Αντίθετα οι υπόλοιπες αλληλεπιδράσεις δεν είναι στατιστικά σημαντικές (έχουν $p>0.05$) και επομένως μπορούν να αφαιρεθούν από το μοντέλο.

```


model17=update(model16, ~ . -landValue:fireplaces -fireplaces:centralAir -landValue:centralAir -fireplace
anova(model16,model17)


## Analysis of Variance Table
##
## Model 1: price ~ landValue + fireplaces + heating + centralAir + landValue:fireplaces +
##           heating:centralAir + landValue:heating + centralAir:fireplaces +
##           landValue:centralAir + fireplaces:heating
## Model 2: price ~ landValue + fireplaces + heating + centralAir + heating:centralAir +
##           landValue:heating
##   Res.Df      RSS Df  Sum of Sq    F  Pr(>F)
## 1    1711 9.2781e+12
## 2    1717 9.3418e+12 -6 -6.371e+10 1.9582 0.06845 .
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1


```


Παρατηρούμε ότι το μοντέλο από το οποίο αφαιρέθηκαν οι μη στατιστικά σημαντικοί όροι δεν έχει στατιστικά σημαντική διαφορά από το αρχικό αφού $p=0.068>0.05$.

```
plot(model17)
```













Παρατηρούμε η κατανομή των υπολοίπων ξεφεύγει από την κανονική (QQplot). Θα πειραματιστούμε λοιπόν με το λογαριθμικό μετασχηματισμό της εξαρτημένης μεταβλητής και της landValue.

```
model18=aov(log(price)~ log(landValue) +fireplaces +heating +centralAir +heating:centralAir +landValue
plot(model18)
```











```
summary(model18)
```


```
##                                     Df Sum Sq Mean Sq F value    Pr(>F)
## log(landValue)                 1  90.01  90.01  707.70 < 2e-16 ***
## fireplaces                     2  20.19   10.10   79.38 < 2e-16 ***
## heating                        2   9.09    4.55   35.75 6.14e-16 ***
## centralAir                     1   5.53    5.53   43.50 5.62e-11 ***
## heating:centralAir             2   0.61    0.30    2.38   0.0929 .
## heating:landValue              3  10.36    3.45   27.15 < 2e-16 ***
## Residuals                      1716 218.26   0.13
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```


Η κατανομή των καταλοίπων είναι σημαντικά βελτιωμένη, προσεγγίζοντας την κανονική. Στο νέο μοντέλο η αλληλεπίδραση των heating και centralAir δεν είναι στατιστικά σημαντική ($p=0.09>0.05$) και επομένως μπορεί να αφαιρεθούν από το μοντέλο. Ακόμα φαίνεται πως η παρατήρηση #1011 έχει άσχημη επίδραση στην παλινδρόμηση και επομένως στο τελικό μοντέλο θα αφαιρεθεί.

```
model19=update(model18, ~. -heating:centralAir, subset=(1:length(price)!=1011))
plot(model19)
```









```
summary.lm(model19)
```

```
##
## Call:
## aov(formula = log(price) ~ log(landValue) + fireplaces + heating +
##       centralAir + heating:landValue, subset = (1:length(price) !=
##       1011))
##
## Residuals:
##      Min        1Q     Median        3Q       Max
## -2.73037 -0.20714  0.00328  0.21584  1.22286
##
## Coefficients:
##                               Estimate Std. Error t value Pr(>|t|)
## (Intercept)               1.086e+01  1.247e-01 87.071 < 2e-16 ***
## log(landValue)            8.739e-02  1.336e-02  6.538 8.17e-11 ***
## fireplaces1-3             1.747e-01  1.806e-02  9.669 < 2e-16 ***
## fireplaces4               9.454e-01  2.452e-01  3.856 0.000119 ***
## heatinghot air             1.901e-01  3.813e-02  4.985 6.81e-07 ***
## heatinghot water/steam    2.082e-01  4.439e-02  4.691 2.93e-06 ***
## centralAirYes              1.239e-01  1.963e-02  6.311 3.51e-10 ***
## heatingelectric:landValue 5.772e-06  1.451e-06  3.979 7.21e-05 ***
## heatinghot air:landValue   3.468e-06  4.084e-07  8.493 < 2e-16 ***
## heatinghot water/steam:landValue 3.117e-06  6.067e-07  5.138 3.10e-07 ***
## ---
```

```

## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 0.3449 on 1717 degrees of freedom
## Multiple R-squared:  0.4006, Adjusted R-squared:  0.3974
## F-statistic: 127.5 on 9 and 1717 DF,  p-value: < 2.2e-16

```

Παρατηρούμε ότι το τελικό μοντέλο έχει στατιστικά σημαντική ερμηνευτική ισχύ της τιμής των σπιτιών (p-value: < 2.2e-16), και σχετικά καλή εξήγηση της μεταβλητής της (~40%). Όλοι οι όροι είναι στατιστικά σημαντικοί.

Μοντέλα με εξαρτημένη μεταβλητή τη newConstruction

Θα προσπαθήσουμε να κατασκευάσουμε κατάλληλο μοντέλο πρόβλεψης για το αν είναι νέα κατασκευή και το βαθμό της συσχέτισης με αυτό των μεταβλητών: ποσοστό αποφοίτων κολεγίου της γειτονιάς, αριθμό δωματίων, τιμής και (εξ ορισμού) ηλικίας της κατασκευής.

```
table(newConstruction)
```

```

## newConstruction
##   No   Yes
## 1647   81

```

```
tapply(price,newConstruction,mean)
```

```

##          No        Yes
## 208507.4 282306.8

```


Παρατηρούμε ότι οι παρατηρήσεις (σπίτια) δεν είναι ισομερώς κατανεμημένες στις δύο κατηγορίες.

```


newCon = as.factor(newConstruction)
levels(newCon) [1] = 0
levels(newCon) [2] = 1
newCon=ifelse(newCon==1,0,1)

```


```
boxplot(pctCollege~newConstruction)
```




```
boxplot(price~newConstruction)
```



```
boxplot(price~newConstruction)
```



```
boxplot(age~newConstruction)
```



Παρατηρούμε σε όλα τα boxplots πως τα επίπεδα της εξαρτημένης μεταβλητής που εξετάζουμε (`newConstruction`) φαίνεται να διαφέρουν για όλες τις εξαρτημένες που επιλέξαμε. Ακολούθως θα το διερευνήσουμε και με τον συντελεστή συσχέτισης του Kendall.

```
cor.test(pctCollege,newCon,method="kendall")
```

```
##  
## Kendall's rank correlation tau  
##  
## data: pctCollege and newCon  
## z = 3.1814, p-value = 0.001466  
## alternative hypothesis: true tau is not equal to 0  
## sample estimates:  
## tau  
## 0.06582315
```

```
cor.test(price,newCon,method="kendall")
```

```
##  
## Kendall's rank correlation tau  
##  
## data: price and newCon  
## z = -7.6348, p-value = 2.262e-14  
## alternative hypothesis: true tau is not equal to 0  
## sample estimates:
```

```

##          tau
## -0.1502536

cor.test(age,newCon,method="kendall")

##
## Kendall's rank correlation tau
##
## data: age and newCon
## z = 14.248, p-value < 2.2e-16
## alternative hypothesis: true tau is not equal to 0
## sample estimates:
##          tau
## 0.2833876

cor.test(rooms,newCon,method="kendall")

##
## Kendall's rank correlation tau
##
## data: rooms and newCon
## z = -8.0407, p-value = 8.936e-16
## alternative hypothesis: true tau is not equal to 0
## sample estimates:
##          tau
## -0.1670935

```

Παρατηρούμε ότι υπάρχει στατιστικά σημαντική θετική συσχέτιση του αν είναι νεόδμητο με την τιμή και με τον αριθμό των δωματίων. Επίσης υπάρχει στατιστικά σημαντική αρνητική συσχέτιση του αν είναι νεόδμητο με το ποσοστό αποφοίτων κολεγίου της γειτονιάς και της ηλικίας της κατασκευής(εξ ορισμού).

Στην περίπτωσή μας έχουμε binary μεταβλητή απόκρισης. Ενδείκνυται λοιπόν η χρήση των γενικευμένων γραμμικών μοντέλων. Θα σχηματίσουμε το μοντέλο με τις κύριες επιδράσεις και τις αλληλεπιδράσεις 2ης τάξης.

```

model180 = glm(newCon~pctCollege+rooms+age+price ,binomial)

## Warning: glm.fit: fitted probabilities numerically 0 or 1 occurred

summary(model180)

##
## Call:
## glm(formula = newCon ~ pctCollege + rooms + age + price, family = binomial)
##
## Deviance Residuals:
##      Min        1Q     Median        3Q       Max 
## -4.0486    0.0000   0.0019   0.0131   2.0288 
##
## Coefficients:
##             Estimate Std. Error z value Pr(>|z|)    
## (Intercept)  1.3850    0.0287  48.000  <2e-16 ***
## pctCollege -0.0001    0.0001 -1.0000   0.3163    
## rooms       0.0001    0.0001  1.0000   0.3163    
## age         0.0001    0.0001  1.0000   0.3163    
## price       0.0001    0.0001  1.0000   0.3163    
##
```

```

## (Intercept) -1.022e+00 9.036e-01 -1.131 0.25788
## pctCollege 4.962e-02 1.512e-02 3.281 0.00103 **
## rooms      -2.673e-01 8.703e-02 -3.072 0.00213 **
## age         6.317e-01 1.044e-01 6.050 1.45e-09 ***
## price       2.245e-06 1.742e-06 1.289 0.19756
## ---
## Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## (Dispersion parameter for binomial family taken to be 1)
##
## Null deviance: 653.91 on 1727 degrees of freedom
## Residual deviance: 260.43 on 1723 degrees of freedom
## AIC: 270.43
##
## Number of Fisher Scoring iterations: 12

```

Όλοι όροι που φαίνονται σημαντικοί στο μοντέλο εκτός της τιμής μπορεί να αφαιρεθεί.

```
model181 = glm(newCon~pctCollege+rooms+age,binomial)
```

```

## Warning: glm.fit: fitted probabilities numerically 0 or 1 occurred

summary(model181)
```

```

##
## Call:
## glm(formula = newCon ~ pctCollege + rooms + age, family = binomial)
##
## Deviance Residuals:
##      Min        1Q     Median        3Q       Max
## -4.1703    0.0000   0.0015   0.0111   1.9831
##
## Coefficients:
##             Estimate Std. Error z value Pr(>|z|)
## (Intercept) -1.11209   0.90040 -1.235 0.216791
## pctCollege   0.05337   0.01490  3.582 0.000341 ***
## rooms       -0.20861   0.07318 -2.851 0.004365 **
## age          0.65330   0.10777  6.062 1.35e-09 ***
## ---
## Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## (Dispersion parameter for binomial family taken to be 1)
##
## Null deviance: 653.91 on 1727 degrees of freedom
## Residual deviance: 262.16 on 1724 degrees of freedom
## AIC: 270.16
##
## Number of Fisher Scoring iterations: 12
```

```
anova(model180,model181,test="Chi")
```

```
## Analysis of Deviance Table
```

```

## 
## Model 1: newCon ~ pctCollege + rooms + age + price
## Model 2: newCon ~ pctCollege + rooms + age
##   Resid. Df Resid. Dev Df Deviance Pr(>Chi)
## 1      1723    260.43
## 2      1724    262.17 -1  -1.7388   0.1873

```

Τα δύο μοντέλα δε φαίνεται να διαφέρουν σημαντικά. Θα προτιμήσουμε το δεύτερο και απλούστερο μοντέλο που ουσιαστικά δεν χάνει κάτι αφαιρώντας τον όρο τιμή που δεν είναι στατιστικά σημαντικός. Όπως είχαμε διαπιστώσει και παραπάνω ο αριθμός των δωματίων έχει θετική συσχέτιση με το αν είναι νεόδμητο ενώ αρνητική σχέση έχει το ποσοστό αποφοίτων κολεγίου της γειτονιάς και ασφαλώς η ηλικία του.